Project 11：基于 UCI Heart Disease 数据集的心脏病早期风险预测分析报告

Project 11 小组

2026 年 10 月 21 日

摘要

本报告围绕 Project 11 的题目要求，基于 UCI 机器学习仓库的 Heart Disease 数据集（Cleveland 子集，303 条记录、14 项指标），完成了从 **子集选择**、**数据清洗**、**描述性统计**、**可视化探索**、**统计检验**到 **分类建模与多指标评价**的完整分析流程。清洗后样本量为 297 例（患病 137 例，占 46.1%）。分析表明：地中海贫血类型（thal）、主要血管染色数（ca）、胸痛类型（cp）、最大心率（thalach）、运动诱发心绞痛（exang）与 ST 段压低程度（oldpeak）是与患病与否关联最强的六项指标。在建模阶段，逻辑回归、决策树、随机森林三种模型的测试集 AUC 分别为 0.947、0.736、0.934；其中逻辑回归在 **敏感度**（82.9%）与整体判别力上表现最佳，最符合本项目“宁要错诊、不要漏诊”的临床导向。全部 Python 源代码见附录 A。

目录

1 项目背景与分析目标 **3**

2 数据集说明与子集选择 **3**

2.1 数据集概览 3

2.2 为什么只选 Cleveland 子集 3

3 数据清洗 **4**

3.1 缺失值处理：直接删除 4

3.2 标签二值化 4

3.3 极端值处理：识别但不剔除 5

4 描述性统计 **5**

4.1 变量类型划分 5

4.2 连续变量的描述性统计量 6

5 可视化分析与图的解释 **7**
5.1 连续型变量：直方图 7
5.2 连续型变量：箱线图 8
5.3 离散型变量：条形图 8
5.4 变量间关系：散点图 9
5.5 相关性热力图 10

6 统计检验：让图形结论站得住 **11**
6.1 Spearman 秩相关（含离散变量与单调关系） 11
6.2 卡方独立性检验（离散变量） 12
6.3 连续变量的组间检验 12

7 分类建模与多指标评价 **13**
7.1 建模设置 13
7.2 评价结果 13
7.3 特征重要性：向医疗人员解释模型 15

8 结论与局限 **15**
8.1 主要结论 15
8.2 局限与后续工作 16

A 完整 Python 源代码 **16**

B 变量字典 **22**

C 会议决议留档 **22**

1 项目背景与分析目标

Project 11 的题目（*Early-Stage Disease Risk Prediction in Healthcare*）要求利用 UCI Heart Disease 数据集，基于 14 项关键医学指标（年龄、性别、胸痛类型、静息血压等）构建分类器，预测患者是否患有心脏病；在充分的探索性数据分析（EDA）与缺失值处理之后，训练多种统计学习分类器，并以 ROC-AUC、敏感度等多指标进行评价；核心目标是**向医疗专业人员提供高度可解释的分析**，量化不同生理指标对疾病风险的相对贡献。

结合会议讨论，本项目确立如下分析原则：

1. **临床导向——“宁要错诊，也不要漏诊”**。漏诊（假阴性 FN）的代价远高于误诊（假阳性 FP），因此模型评价以**敏感度（Sensitivity/Recall）**为首要指标，同时报告特异度、精确率、准确率、F1 与 ROC-AUC。

2. **单个子集原则**。仅使用 Cleveland 子集（理由见第 2 节），不混入 Hungarian、Switzerland、Long Beach VA 三个子集。

3. **缺失值直接删除**。Cleveland 子集仅 6 条记录含缺失值，占比约 2%，统计学上可以接受直接删除（见第 3 节）。

4. **极端值保留**。极端值（如胆固醇 564 mg/dl）是真实存在的临床现象，不是数据质量问题，予以保留；仅用 1.5×IQR 规则在箱线图中进行**识别与标注**，不作剔除。

5. **可解释性优先**。每一张图、每一个统计量都配文字解释，全部源代码留档（附录 A），保证过程可复现。

2 数据集说明与子集选择

2.1 数据集概览

UCI Heart Disease 数据集由四个医疗机构的子集构成：Cleveland（克利夫兰）、Hungarian（匈牙利）、Switzerland（瑞士）与 Long Beach VA（弗吉尼亚长滩）。原始数据包含 76 个属性，但数据说明文档（`heart-disease.names`）明确指出，已发表研究均只使用其中 14 个属性，本报告沿用这一惯例。14 项指标的含义见附录 B。

2.2 为什么只选 Cleveland 子集

对四个子集的缺失情况进行统计（表 1），可以发现：

表 1 四个子集的缺失值情况对比

子集	样本量	缺失单元格数	含缺失的记录数	含缺失记录占比
Cleveland	303	**6**	**6**	**2.0%**
Hungarian	294	782	293	99.7%
Switzerland	123	273	123	100%
Long Beach VA	200	698	199	99.5%

选择 Cleveland 子集的理由有三：

1. **数据完整性完全不同量级**。其余三个子集几乎**每一条**记录都含缺失值（整列的“?”）。若强行纳入，只能大面积插补——用众数/中位数填补超过一半的观测会严重扭曲变量分布，使后续建模结论失真；
2. **与本项目的临床导向一致**。“宁错诊不漏诊”要求模型学到真实的指标—疾病关系。用大量人造填补值训练出的模型不可信；
3. **符合文献惯例**。该数据集的说明文档及绝大多数已发表研究均基于 Cleveland 子集完成，便于与文献结果对照。

3 数据清洗

3.1 缺失值处理：直接删除

Cleveland 子集的缺失值集中在两个离散变量上：`ca`（主要血管染色数，缺失 4 条）与 `thal`（地中海贫血类型，缺失 2 条），共 6 条记录。

会议讨论了两种方案：

- **方案 A（压缩样本量）**：直接删除含缺失值的记录；
- **方案 B（保持样本量）**：用众数/中位数插补。

最终采用方案 A，依据如下：缺失记录为 $6/303 \approx 2.0\%$，删除后样本量仍有 297，对统计功效影响极小；而插补会把 6 名患者强行推向“常见类型”，在样本量本就有限的情况下人为制造偏差。删除缺失值在统计学惯例上（缺失比例 $< 5\%$）完全可以接受。

3.2 标签二值化

原始标签 `target` 取值 $0 \sim 4$（0 = 未患病，$1 \sim 4$ = 患病程度）。按文献惯例与本项目“是否患病”的二分类目标，将 $1 \sim 4$ 合并为 1。清洗后类别分布为：未患病 160 例（53.9%），患病 137 例（46.1%），**类别基本均衡**（图 1），无需做过采样/欠采样处理。

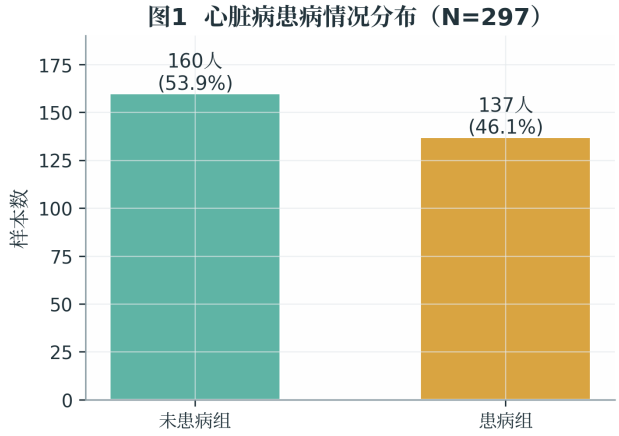


图 1 清洗后样本的患病情况分布。两组样本量接近（160 vs 137），阳性占比 46.1%，说明该数据集不存在类别不平衡问题，准确率（Accuracy）仍是有意义的评价指标，敏感度、特异度也可直接解读。

3.3 极端值处理：识别但不剔除

以血清胆固醇为例，最大值 564 mg/dl，远超上四分位数（276 mg/dl）。会议讨论后决定**保留**，理由：3σ 原则适用于工业质量控制（剔除“不合格产品”），而医学数据中的极端值是**真实存在的患者状态**，剔除会丢掉高风险个体信息，恰恰违背“不漏诊”的目标。本报告仅在箱线图中按 $1.5 \times \text{IQR}$ 规则将其标注为离群点（见第 5.2 节），供读者知悉。

4 描述性统计

4.1 变量类型划分

按会议确定的规则：取值种类多、且样本量大于 30 的变量按**连续型**处理，可用直方图、箱线图、散点图分析，并可近似视为正态（中心极限定理）；取值为少数几个编码的变量按**离散型**处理，用条形图（各类别患病率）展示。划分结果：

- 连续型（5 个）：age（年龄）、trestbps（静息血压）、chol（血清胆固醇）、thalach（最大心率）、oldpeak（ST 段压低程度）；
- 离散型（8 个）：sex、cp、fbs、restecg、exang、slope、ca、thal。

4.2 连续变量的描述性统计量

表 2 连续型变量的描述性统计（N=297）

指标	均值	标准差	最小值	Q_1	中位数	Q_3	最大值	IQR
年龄（岁）	54.54	9.05	29	48	56	61	77	13.0
静息血压（mmHg）	131.69	17.76	94	120	130	140	200	20.0
血清胆固醇（mg/dl）	247.35	52.00	126	211	243	276	564	65.0
最大心率（次/分）	149.60	22.94	71	133	153	166	202	33.0
ST 段压低程度	1.06	1.17	0.0	0.0	0.8	1.6	6.2	1.6

四分位数采用位置法计算：Q_1 位于第 $(N+1)/4$ 个排序位置，Q_3 位于第 $3(N+1)/4$ 个位置；若位置不是整数，则在相邻两个观测值之间按距离加权插值（例如位置为 $k.75$，则取 $0.25\,x_{(k)} + 0.75\,x_{(k+1)}$）。本数据集 $N+1 = 304$ 可被 4 整除，Q_1、中位数、Q_3 恰好落在整数位置上，无需插值。该结果与 Excel 的 `QUARTILE.INC` 函数口径一致。

表 3 连续变量的分组均值对比

指标	未患病组均值	患病组均值	差值方向
年龄（岁）	52.64	56.76	患病组更高
静息血压（mmHg）	129.18	134.64	患病组更高
血清胆固醇（mg/dl）	243.49	251.85	患病组略高
最大心率（次/分）	**158.58**	**139.11**	**患病组明显更低**
ST 段压低程度	**0.60**	**1.59**	**患病组明显更高**

表 3 已提示：最大心率与 ST 段压低程度在两组间的差距最大，是最有潜力的判别指标——这一猜想将在后续图表与统计检验中得到验证。

5 可视化分析与图的解释

5.1 连续型变量：直方图

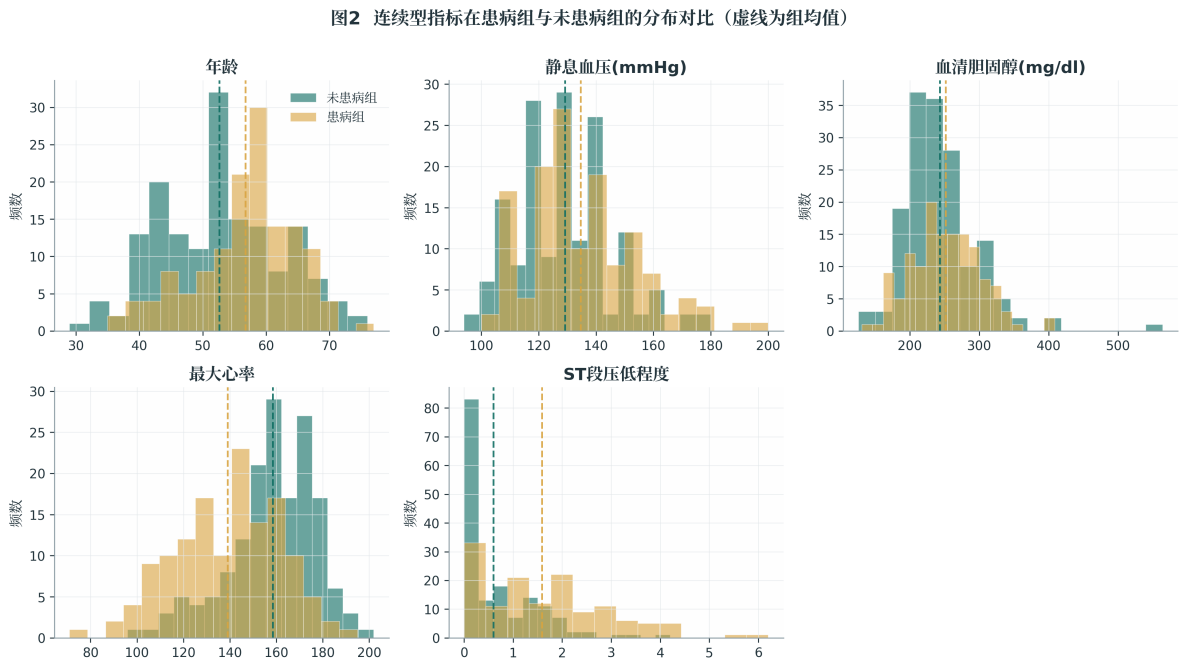


图 2 五个连续型指标在患病组（金色）与未患病组（蓝绿色）的分布对比，虚线为各组均值。

图的解释（图 2）：

- **年龄**：未患病组峰值在 52 岁附近，患病组分布整体右移、峰值约 57 岁——患病群体年龄更大，符合“年龄是心血管疾病的经典危险因素”的医学常识；
- **静息血压**：两组高度重叠，患病组均值略高（134.6 vs 129.2 mmHg），单独区分能力有限；
- **血清胆固醇**：两组几乎重合，且可见 400~564 mg/dl 的极端值长尾（即会议中讨论的“500 多的胆固醇”），进一步说明极端值只是少数真实患者，不影响整体分布形态；
- **最大心率**：两组分离最明显——未患病组集中在 150~170 次/分，患病组集中在 120~150 次/分，均值差近 20 次/分，提示心脏储备功能下降与患病密切相关；
- **ST 段压低程度**：未患病组 80 余人集中在 0（无压低），患病组则广泛分布在 0.5 ~ 4 区间。运动诱发心肌缺血（ST 压低）是冠心病负荷试验的经典阳性表现，与数据一致。

5.2　连续型变量：箱线图

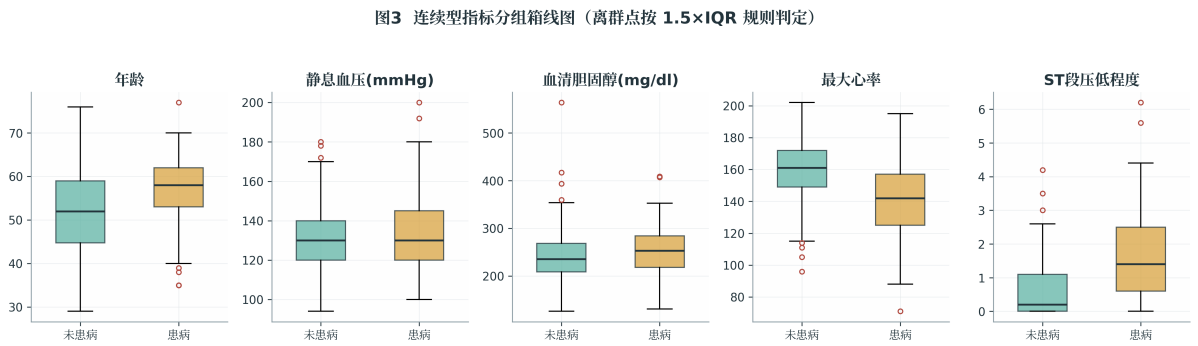


图 3　五个连续型指标的分组箱线图。箱体为 $Q_1 \sim Q_3$，箱内横线为中位数；上下“围栏”为 $Q_1 - 1.5 \times \mathrm{IQR}$ 与 $Q_3 + 1.5 \times \mathrm{IQR}$（上下各 1.5 个 IQR，加箱体本身共 4 个 IQR）；围栏之外的点即为离群点，以空心圆标注。

图的解释（图 3）：箱线图的上下边界并非传统的最大值/最小值，而是“围栏之内”的最大/最小观测值；超出围栏的点被判定为离群点。按 1.5×IQR 规则统计：年龄 0 个、静息血压 9 个、胆固醇 5 个、最大心率 1 个、ST 段压低 5 个离群点。从组间对比看：**最大心率**患病组的中位数（约 141）甚至低于未患病组的下四分位数（约 133 附近以下），箱体几乎不重叠，区分力最强；**ST 段压低**两组中位数差距约 1.0，差异同样显著；而**胆固醇**两组箱体高度重叠，中位数几乎相等，直观解释了为什么它在 t 检验中不显著（见第 6 节）。

5.3　离散型变量：条形图

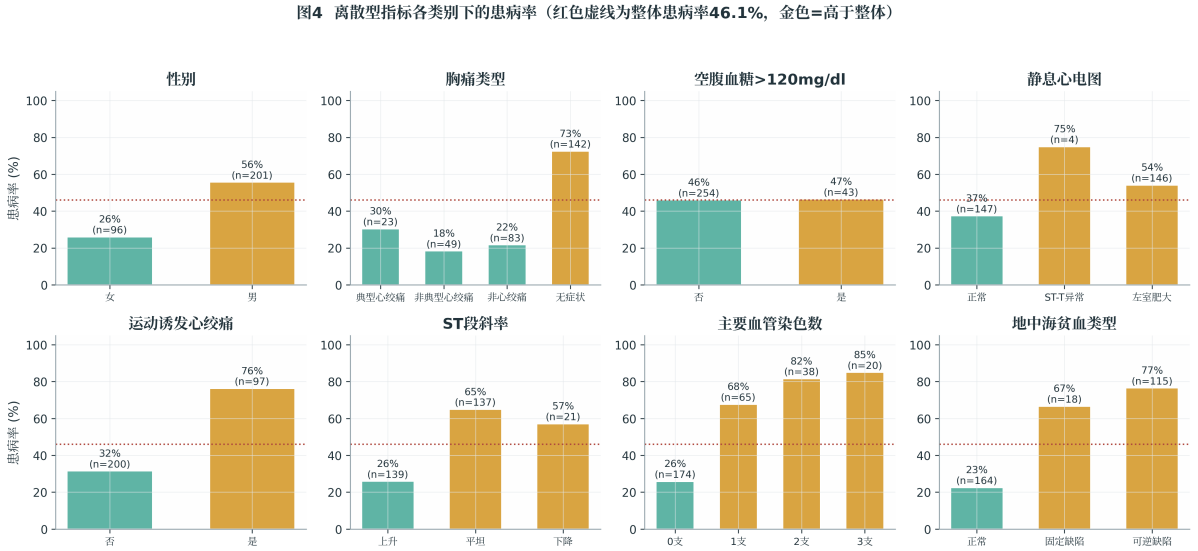


图 4　八个离散型指标各类别下的患病率（柱顶标注百分比与样本量 n）。红色虚线为整体患病率 46.1%；金色柱表示该类别患病率高于整体水平，蓝绿色柱表示低于整体水平。

图的解释（图 4）：

- **性别**：男性患病率 56%，女性仅 26%——男性风险明显更高（注意：该数据集男性样本占 2/3，解读时需注意抽样结构）；
- **胸痛类型**：最具有“反直觉”价值的一幅图。有典型/非典型心绞痛症状者患病率反而只有 18%~30%，而 **无症状（编码 4）者患病率高达 73%**。这说明“没有胸痛”绝不等于“没有心脏病”，恰恰印证了本项目**早期筛查**的现实意义——无症状人群的漏诊风险最高；
- **空腹血糖**：两类患病率几乎相同（46% vs 47%），提示该指标在本数据集中几乎不含判别信息；
- **运动诱发心绞痛**：是（76%）与否（32%）差异悬殊；
- **ST 段斜率**：平坦（65%）与下降（57%）远高于上升（26%），与运动试验判读规则一致；
- **主要血管染色数（ca）**：呈现清晰的**剂量-反应关系**——0 支 26%、1 支 68%、2 支 82%、3 支 85%，病变血管越多患病率越高，单调递增，是最有说服力的指标之一；
- **地中海贫血类型（thal）**：正常者患病率仅 23%，可逆缺陷者高达 77%。

5.4　变量间关系：散点图

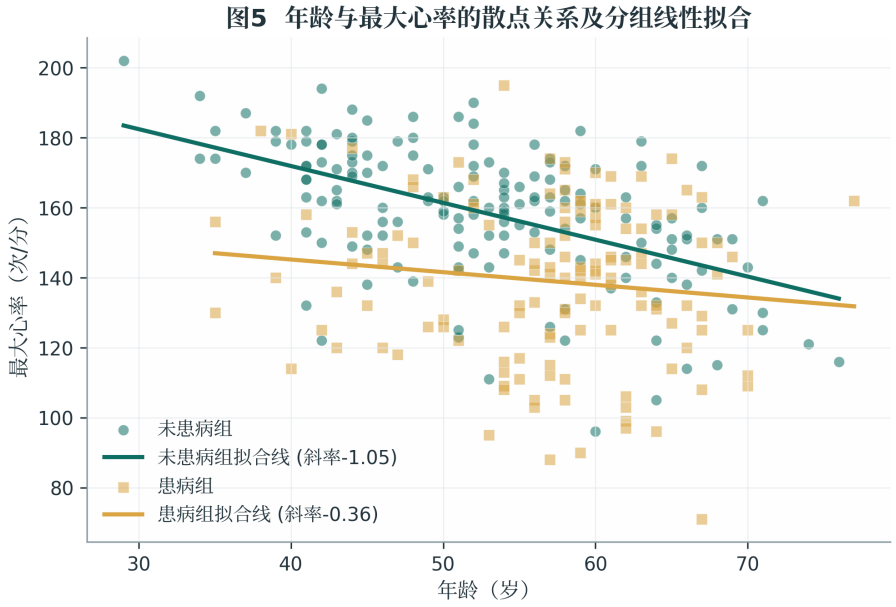


图 5　年龄与最大心率的散点图及分组线性拟合。

图的解释（图 5）：两组的拟合线均向下倾斜，说明无论是否患病，年龄越大、能达到的最大心率越低（符合生理学规律）；但**患病组（金色）的拟合线整体位于未患病组（蓝绿色）下方约 15~20 次/分**——即在**相同年龄**下，患病者能达到的最大心率系统性更低。这说明最大心率对患病的判别信息**不能被年龄替代**，两者应同时进入模型；也直观说明心脏病不能被任何单一变量唯一决定，需要多变量联合建模。

5.5　相关性热力图

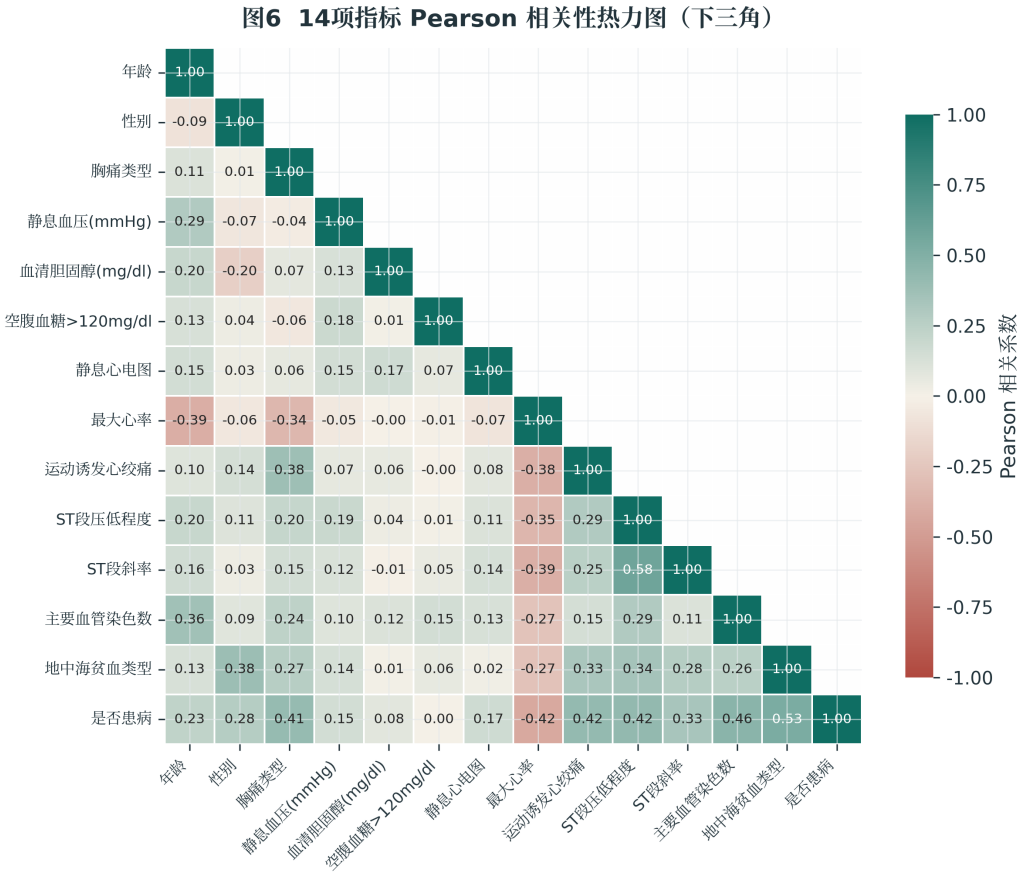


图 6　14 项指标的 Pearson 相关系数热力图（下三角）。蓝绿色为正相关，红色为负相关，颜色越深相关越强。

图的解释（图 6）：最下面一行（“是否患病”行）是重点：与患病正相关最强的是地中海贫血类型（0.53）、主要血管染色数（0.46）、运动诱发心绞痛（0.42）、ST 段压低程度（0.42）、胸痛类型（0.41）；负相关最强的是最大心率（−0.42）。另一方面，特征之间的相关系数绝对值普遍不超过 0.6（最高为 ST 段斜率与 ST 段压低的 −0.58），说明 13 个特征提供了**互补而非冗余**的信息——没有任何一个变量能唯一决定心脏病，必须依靠多变量模型，这为后续多元建模提供了直接依据。

6 统计检验：让图形结论站得住

图形直观但不足以定论，本节用三类检验给出统计证据。

6.1 Spearman 秩相关（含离散变量与单调关系）

Pearson 相关只适用于连续变量的线性关系；Spearman 秩相关对单调关系与离散编码变量同样适用，且不受极端值（如胆固醇 564）影响。

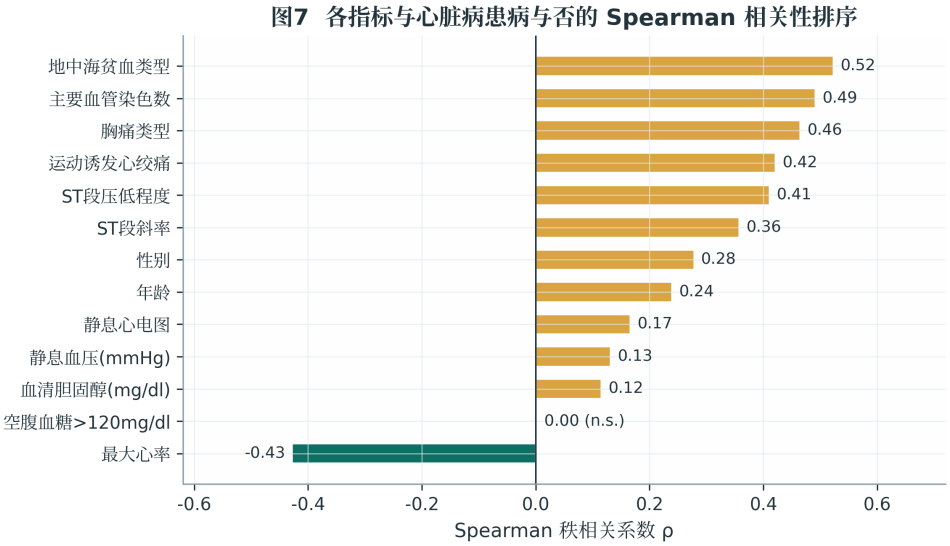


图 7 各指标与“是否患病”的 Spearman 秩相关系数排序。金色为显著正相关，蓝绿色为显著负相关，灰色（n.s.）为不显著。

表 4 Spearman 秩相关检验结果（按 $|\rho|$ 排序）

指标	ρ	p 值	指标	ρ	p 值
地中海贫血类型	0.523	<0.001	ST 段斜率	0.358	<0.001
主要血管染色数	0.492	<0.001	性别	0.279	<0.001
胸痛类型	0.465	<0.001	年龄	0.240	<0.001
最大心率	−0.429	<0.001	静息心电图	0.166	0.004
运动诱发心绞痛	0.421	<0.001	静息血压	0.132	0.023
ST 段压低程度	0.411	<0.001	血清胆固醇	0.116	0.046
			空腹血糖	0.003	0.957（不显著）

除空腹血糖外，12 项指标与患病与否均存在统计显著的单调关联（$p < 0.05$），与热力图、条形图的结论一致。

6.2 卡方独立性检验（离散变量）

对 8 个离散变量分别构建“类别 × 是否患病”列联表，进行 Pearson χ^2 独立性检验：

表 5 离散变量的卡方独立性检验

指标	χ^2 统计量	自由度	p 值
地中海贫血类型	82.46	2	<0.001
胸痛类型	77.28	3	<0.001
主要血管染色数	72.30	3	<0.001
运动诱发心绞痛	50.94	1	<0.001
ST 段斜率	43.47	2	<0.001
性别	21.85	1	<0.001
静息心电图	9.58	2	0.008
空腹血糖	0.00	1	1.000（不显著）

原假设“该指标与是否患病相互独立”在 7 个变量上均被拒绝（$p < 0.01$），只有空腹血糖不能拒绝原假设——这与图 4 中其两根柱子几乎等高、Spearman 检验不显著相互印证。三重证据一致，说明结论稳健。

6.3 连续变量的组间检验

对 5 个连续变量做 Welch 双样本 t 检验，并以 Mann-Whitney U 非参数检验复核（避免对正态性的依赖）：

表 6 连续变量的组间差异检验

指标	患病组均值	未患病组均值	Welch t 检验 p 值	M-W U 检验 p 值
年龄	56.76	52.64	<0.001	<0.001
最大心率	139.11	158.58	<0.001	<0.001
ST 段压低程度	1.59	0.60	<0.001	<0.001
静息血压	134.64	129.18	0.009	0.024
血清胆固醇	251.85	243.49	0.165（不显著）	0.047

胆固醇的 t 检验不显著而 M-W 检验勉强显著，正是其分布长尾（极端值）干扰参数检验的典型表现，也说明该指标判别力有限。

7 分类建模与多指标评价

7.1 建模设置

- **特征与标签**：13 项指标为特征，二值化 target 为标签；
- **数据划分**：按 75%/25% 分层抽样划分训练集（223 例）与测试集（74 例），随机种子 42，保证两组类别比例一致；
- **模型**：逻辑回归（可解释性最强，系数可直接解读）、决策树（深度限制为 4，规则可读）、随机森林（300 棵树，深度限制为 5，非线性基准）。逻辑回归输入经标准化处理；
- **评价指标**：混淆矩阵四要素（TP/FP/TN/FN）、准确率、**敏感度**（$TP/(TP+FN)$，不漏诊能力）、**特异度**（$TN/(TN+FP)$，不误诊能力）、精确率、F1、ROC-AUC，并辅以 5 折交叉验证 AUC 检验稳定性。

7.2 评价结果

表 7 三种模型在测试集上的评价指标对比

模型	准确率	**敏感度**	特异度	精确率	F1	测试集 AUC	5 折 CV AUC
逻辑回归	**0.853**	**0.829**	0.875	**0.853**	**0.841**	**0.947**	0.894
决策树	0.693	0.657	0.725	0.676	0.667	0.736	0.813
随机森林	0.827	0.771	0.875	0.844	0.806	0.934	**0.898**

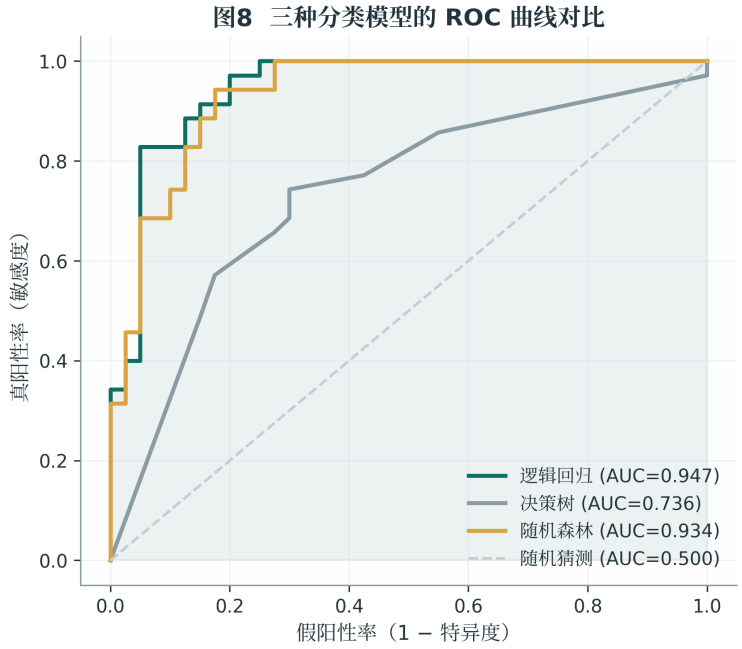


图 8 三种模型的 ROC 曲线。曲线越贴近左上角，判别力越强；逻辑回归与随机森林明显优于决策树。

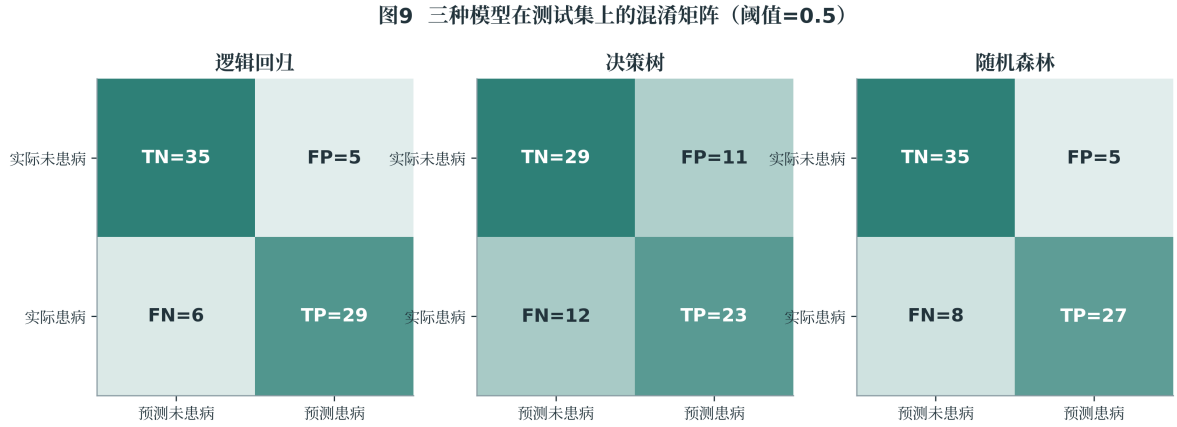


图 9 三种模型在测试集上的混淆矩阵（判定阈值 0.5）。TN= 真阴性，FP= 假阳性（误诊），FN= 假阴性（漏诊），TP= 真阳性。本项目最忌讳漏诊：逻辑回归 FN=6，少于决策树的 12 与随机森林的 8。

结果解读：

1. **逻辑回归是本项目首选模型**：测试集 AUC 0.947、敏感度 82.9%，在 35 例真实患病者中仅漏诊 6 例；且系数可直接向医疗人员解释（见下文特征重要性），最契合题目“高度可解释”的要求；

2. 决策树虽然规则最直观，但判别力明显不足（AUC 0.736、漏诊 12 例），说明该问题存在单棵树难以刻画的特征交互；

3. 随机森林交叉验证 AUC 最高（0.898），泛化最稳，但敏感度（77.1%）低于逻辑回归，且解释性较弱，可作为辅助模型；

4. 若临床场景进一步强调“零漏诊”，可在逻辑回归基础上 **下调判定阈值**（如 0.5→0.35），以少量特异度换取更高敏感度——这正是 ROC 曲线给出的可调空间。

7.3 特征重要性：向医疗人员解释模型

图10 模型视角下的指标重要性（左：逻辑回归系数；右：随机森林重要性）

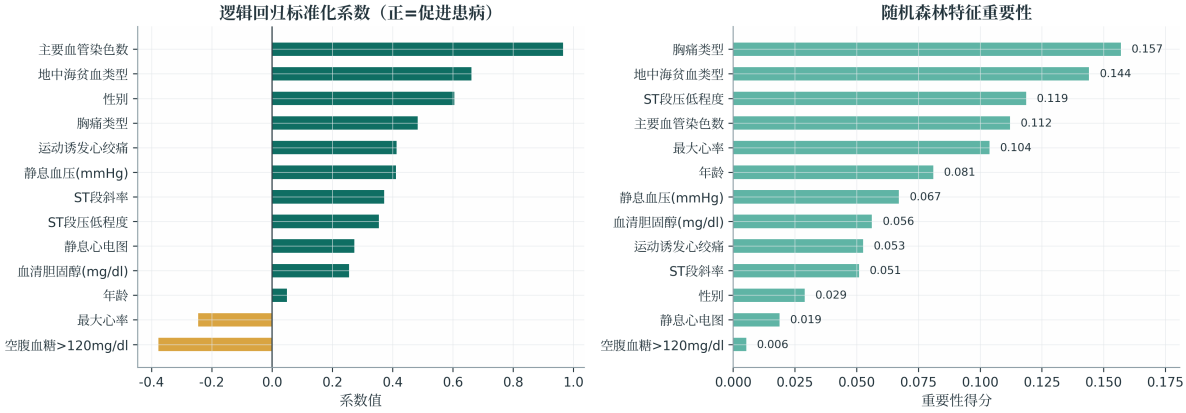


图 10 模型视角的指标重要性。左：逻辑回归标准化系数（特征经标准化，系数可直接比较大小；正值促进患病、负值抑制）；右：随机森林特征重要性得分。

图的解释（图 10）：两种口径相互印证：**主要血管染色数、地中海贫血类型、胸痛类型、最大心率、ST 段压低程度**稳定地排在重要性前列，与 Spearman 检验、卡方检验的排序高度一致。逻辑回归系数还给出方向性解释：血管染色数每增加一个标准差，患病对数几率上升最多（系数 0.97）；最大心率系数为负（−0.25），即同等条件下心率越高风险越低。空腹血糖在两个模型中均接近零贡献，建议临床解读时弱化该指标。这种“统计检验 + 可视化 + 双模型交叉验证”三者一致的结论链，构成了对医疗专业人员有说服力的可解释分析。

8 结论与局限

8.1 主要结论

1. 数据层面：Cleveland 子集质量远优于其余三个子集；删除 2% 缺失记录后，297 例样本类别均衡，可直接建模；

2. 指标层面：thal、ca、cp、thalach、exang、oldpeak 六项指标与患病关联最强（三种统计检验一致）；fbs 几乎无判别信息；chol 判别力弱且受极端值干扰；

3. 模型层面：逻辑回归以 AUC 0.947、敏感度 82.9%、漏诊仅 6 例的表现成为首选模型，且完全可解释；随机森林泛化能力略优，可作辅助；

4. 临床层面：无症状（cp=4）人群患病率高达 73%，凸显早期筛查的必要性；血管染色数呈单调剂量-反应关系，是最有说服力的单项风险信号。

8.2 局限与后续工作

1. 样本来自单一机构（Cleveland），且男性占 2/3，外推到其他人群需谨慎；后续可在控制地区因素的前提下评估其余子集；

2. 样本量 297 限制了复杂模型的使用，本报告对树模型均做了深度限制以防过拟合；

3. 后续可按计划进一步调优判定阈值（提升敏感度）、尝试交叉验证下的特征筛选，并补充 ROC-AUC 之外的 PR 曲线等评价视角。

A 完整 Python 源代码

以下代码按报告章节顺序组织，可直接运行复现全部表格与图片（依赖：pandas、numpy、matplotlib、seaborn、scipy、scikit-learn）。

A.1 数据读取与清洗（对应第 2、3 章）

```python
import pandas as pd
import numpy as np

# 14个精选指标的列名（heart-disease.names 文档中 published 的字段）
cols = ['age', 'sex', 'cp', 'trestbps', 'chol', 'fbs', 'restecg',
        'thalach', 'exang', 'oldpeak', 'slope', 'ca', 'thal', 'target']

# 缺失值以 "?" 标记，读取时转换为 NaN
raw = pd.read_csv('processed.cleveland.data',
                  header=None, names=cols, na_values='?')

# --- 子集选择依据：统计四个子集的缺失情况（表1） ---
for name in ['hungarian', 'switzerland', 'va']:
    d = pd.read_csv(f'processed.{name}.data',
                    header=None, names=cols, na_values='?')
    print(name, d.shape,
          'missing cells:', int(d.isna().sum().sum()),
          'rows with any missing:', int(d.isna().any(axis=1).sum()))

# --- 缺失值处理：直接删除（6/303 约等于 2%，统计学可接受） ---
```

```
df = raw.dropna().copy()

# --- 标签二值化：0=未患病；1~4 合并为 1=患病 ---
df['target'] = (df['target'] > 0).astype(int)

# 离散变量转整数类型，便于分组统计
for c in ['sex', 'cp', 'fbs', 'restecg', 'exang', 'slope', 'ca', 'thal']:
    df[c] = df[c].astype(int)

print('清洗后样本量:', df.shape)           # (297, 14)
print(df['target'].value_counts())          # 0:160, 1:137
```

A.2 描述性统计（对应第 4 章）

```
cont = ['age', 'trestbps', 'chol', 'thalach', 'oldpeak']  # 连续型变量

# 五数概括 + 均值/标准差 + IQR（表2）
# 四分位数为位置法口径，与 Excel 的 QUARTILE.INC 一致
desc = df[cont].describe().T
desc['median'] = df[cont].median()
desc['IQR'] = desc['75%'] - desc['25%']
print(desc.round(2))

# 分组均值对比（表3）
print(df.groupby('target')[cont].mean().round(2))

# 1.5*IQR 规则识别离群点（只标注，不剔除）
for c in cont:
    q1, q3 = df[c].quantile([0.25, 0.75])
    iqr = q3 - q1
    n_out = int(((df[c] < q1 - 1.5 * iqr) | (df[c] > q3 + 1.5 * iqr)).sum()
        )
    print(c, 'outliers:', n_out)
```

A.3 可视化绘图（对应第 5 章，图 1~ 图 6）

```
import matplotlib.pyplot as plt
import matplotlib as mpl
from matplotlib.colors import LinearSegmentedColormap
import seaborn as sns

# ---- 统一风格：蓝绿主色 + 金色强调 ----
TEAL, TEAL_L, GOLD = '#0F6E63', '#5FB4A5', '#D9A441'
```

```
INK, GREY = '#22333B', '#8A9BA3'
mpl.rcParams.update({
    'figure.dpi': 150, 'savefig.dpi': 300, 'savefig.bbox': 'tight',
    'axes.grid': True, 'grid.color': '#E4E9EC',
    'axes.spines.top': False, 'axes.spines.right': False,
    'legend.frameon': False,
})
grp_lab = {0: '未患病组', 1: '患病组'}

# ---- 图1: 目标变量分布 ----
fig, ax = plt.subplots(figsize=(5.2, 3.6))
counts = df['target'].value_counts().sort_index()
bars = ax.bar(['未患病组', '患病组'], counts.values,
              color=[TEAL_L, GOLD], width=0.55)
for b, v in zip(bars, counts.values):
    ax.text(b.get_x() + b.get_width() / 2, v + 2,
            f'{v}人\n({v/len(df)*100:.1f}%)', ha='center')
ax.set_title('图1 心脏病患病情况分布 (N=297) ')
plt.savefig('figures/fig1_target_dist.png')

# ---- 图2: 连续型变量分组直方图 ----
fig, axes = plt.subplots(2, 3, figsize=(13, 7.2))
for i, c in enumerate(cont):
    ax = axes.ravel()[i]
    for g, col in [(0, TEAL), (1, GOLD)]:
        ax.hist(df.loc[df.target == g, c], bins=15, alpha=0.62,
                color=col, label=grp_lab[g], edgecolor='white')
        ax.axvline(df.loc[df.target == g, c].mean(),
                   color=col, ls='--', lw=1.4)   # 组均值虚线
    ax.set_title(c)
axes.ravel()[0].legend()
axes.ravel()[5].axis('off')
plt.tight_layout()
plt.savefig('figures/fig2_hist_cont.png')

# ---- 图3: 分组箱线图 (1.5*IQR 围栏 + 离群点) ----
fig, axes = plt.subplots(1, 5, figsize=(14.5, 4.2))
for i, c in enumerate(cont):
    data = [df.loc[df.target == g, c] for g in [0, 1]]
    bp = axes[i].boxplot(data, tick_labels=['未患病', '患病'],
                         patch_artist=True, widths=0.5,
                         flierprops=dict(marker='o', markersize=4,
                                         markerfacecolor='none',
                                         markeredgecolor='#B0483E'))
    for patch, col in zip(bp['boxes'], [TEAL_L, GOLD]):
```

```
        patch.set_facecolor(col); patch.set_alpha(0.75)
    axes[i].set_title(c)
plt.tight_layout()
plt.savefig('figures/fig3_boxplot.png')

# ---- 图4: 离散型变量各类别患病率条形图 ----
disc = ['sex', 'cp', 'fbs', 'restecg', 'exang', 'slope', 'ca', 'thal']
fig, axes = plt.subplots(2, 4, figsize=(14.5, 6.8))
for i, c in enumerate(disc):
    ax = axes.ravel()[i]
    rate = df.groupby(c)['target'].mean()
    n = df.groupby(c).size()
    cols_bar = [GOLD if r >= df['target'].mean() else TEAL_L
                for r in rate.values]
    bars = ax.bar(rate.index.astype(str), rate.values * 100,
                  color=cols_bar, width=0.6)
    for b, r, nn in zip(bars, rate.values, n.values):
        ax.text(b.get_x() + b.get_width() / 2, r * 100 + 2,
                f'{r*100:.0f}%\n(n={nn})', ha='center', fontsize=8.6)
    ax.axhline(df['target'].mean() * 100, color='#B0483E', ls=':')
    ax.set_title(c); ax.set_ylim(0, 105)
plt.tight_layout()
plt.savefig('figures/fig4_bar_disc.png')

# ---- 图5: 年龄 vs 最大心率散点图 + 分组拟合线 ----
fig, ax = plt.subplots(figsize=(7.6, 4.8))
for g, col, mk in [(0, TEAL, 'o'), (1, GOLD, 's')]:
    sub = df[df.target == g]
    ax.scatter(sub['age'], sub['thalach'], c=col, alpha=0.55,
               s=32, marker=mk, label=grp_lab[g])
    z = np.polyfit(sub['age'], sub['thalach'], 1)
    xs = np.linspace(sub['age'].min(), sub['age'].max(), 50)
    ax.plot(xs, np.polyval(z, xs), color=col, lw=2.2,
            label=f'{grp_lab[g]}拟合线 (斜率{z[0]:.2f})')
ax.set_xlabel('年龄 (岁)'); ax.set_ylabel('最大心率 (次/分)')
ax.legend()
plt.savefig('figures/fig5_scatter.png')

# ---- 图6: Pearson 相关性热力图 (下三角) ----
corr = df.corr()
mask = np.triu(np.ones_like(corr, dtype=bool), k=1)
cmap = LinearSegmentedColormap.from_list('tg',
        ['#B0483E', '#F5F1E8', TEAL])
fig, ax = plt.subplots(figsize=(8.6, 7))
sns.heatmap(corr, mask=mask, cmap=cmap, vmin=-1, vmax=1, center=0,
```

```
            annot=True, fmt='.2f', square=True, linewidths=0.5,
            cbar_kws={'label': 'Pearson 相关系数'}, ax=ax)
plt.savefig('figures/fig6_heatmap.png')
```

A.4 统计检验（对应第 6 章，含图 7）

```
from scipy import stats

# ---- Spearman 秩相关（表4 + 图7） ----
sp_res = []
for c in cols[:-1]:
    r, p = stats.spearmanr(df[c], df['target'])
    sp_res.append((c, r, p))
sp_df = (pd.DataFrame(sp_res, columns=['指标', 'rho', 'p值'])
           .sort_values('rho', key=abs, ascending=False))
print(sp_df.round(4))

# 图7: Spearman 系数排序条形图
fig, ax = plt.subplots(figsize=(7.8, 4.6))
sp_plot = sp_df.sort_values('rho')
sig = sp_plot['p值'] < 0.05
colors = [GOLD if (s and r > 0) else (TEAL if s else GREY)
          for s, r in zip(sig, sp_plot['rho'])]
ax.barh(sp_plot['指标'], sp_plot['rho'], color=colors, height=0.62)
ax.axvline(0, color=INK, lw=0.9)
plt.savefig('figures/fig7_spearman.png')

# ---- 卡方独立性检验（表5） ----
for c in disc:
    ct = pd.crosstab(df[c], df['target'])
    chi2, p, dof, _ = stats.chi2_contingency(ct)
    print(c, f'chi2={chi2:.2f}, dof={dof}, p={p:.4g}')

# ---- 连续变量组间检验：Welch t + Mann-Whitney U（表6） ----
for c in cont:
    a = df.loc[df.target == 1, c]
    b = df.loc[df.target == 0, c]
    t, p_t = stats.ttest_ind(a, b, equal_var=False)
    u, p_u = stats.mannwhitneyu(a, b, alternative='two-sided')
    print(c, f't-p={p_t:.4g}, mw-p={p_u:.4g}')
```

A.5 建模与评价（对应第 7 章，图 8~ 图 10）

```python
from sklearn.model_selection import (train_test_split,
                                     StratifiedKFold, cross_val_score)
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import confusion_matrix, roc_curve, auc

X, y = df[cols[:-1]], df['target']
# 分层抽样：训练/测试 = 75%/25%，类别比例保持一致
X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y)

models = {
    '逻辑回归': Pipeline([('sc', StandardScaler()),
        ('clf', LogisticRegression(max_iter=1000, random_state=42))]),
    '决策树': DecisionTreeClassifier(max_depth=4, random_state=42),
    '随机森林': RandomForestClassifier(n_estimators=300,
                                     max_depth=5, random_state=42),
}
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

for name, m in models.items():
    m.fit(X_tr, y_tr)
    prob = m.predict_proba(X_te)[:, 1]
    pred = (prob >= 0.5).astype(int)
    tn, fp, fn, tp = confusion_matrix(y_te, pred).ravel()
    fpr, tpr, _ = roc_curve(y_te, prob)
    print(name,
          '敏感度=%.3f' % (tp / (tp + fn)),   # 不漏诊能力（首要指标）
          '特异度=%.3f' % (tn / (tn + fp)),   # 不误诊能力
          'AUC=%.3f' % auc(fpr, tpr),
          'CV-AUC=%.3f' % cross_val_score(
              m, X, y, cv=cv, scoring='roc_auc').mean())
    # 图8 ROC / 图9 混淆矩阵 / 图10 特征重要性的绘图代码
    # 与 A.3 中 matplotlib 用法相同，此处从略（完整文件可复现）。
```

B 变量字典

表 8 14 项指标含义说明（据 heart-disease.names 文档整理）

字段名	中文含义	类型	取值说明
age	年龄	连续	29~77 岁
sex	性别	离散	1= 男，0= 女
cp	胸痛类型	离散	1= 典型心绞痛，2= 非典型，3= 非心绞痛，4= 无症状
trestbps	静息血压	连续	mmHg（入院时测量）
chol	血清胆固醇	连续	mg/dl
fbs	空腹血糖 >120mg/dl	离散	1= 是，0= 否
restecg	静息心电图结果	离散	0= 正常，1=ST-T 异常，2= 左室肥大
thalach	最大心率	连续	次/分（运动试验达到）
exang	运动诱发心绞痛	离散	1= 是，0= 否
oldpeak	ST 段压低程度	连续	运动相对静息的压低值
slope	ST 段斜率	离散	1= 上升，2= 平坦，3= 下降
ca	主要血管染色数	离散	0~3（荧光造影）
thal	地中海贫血类型	离散	3= 正常，6= 固定缺陷，7= 可逆缺陷
target	是否患病（标签）	离散	0= 未患病，1~4= 患病（本文合并为 1）

C 会议决议留档

1. 数据集：使用 UCI Heart Disease 的 Cleveland 单子集；其余三个子集因缺失值过多（几乎每行都有缺失）不纳入分析；

2. 缺失值：直接删除（6/303 ≈ 2%，统计学上可接受）；极端值暂不剔除，保留原数据，仅在箱线图中标注；

3. 图表规范：连续型变量用直方图/箱线图/散点图，离散型变量用条形图；箱线图离群点统一按 1.5×IQR 判定；四分位数用 Excel 函数（QUARTILE.INC 口径）核对；

4. 可视化配色：蓝绿配色为主、金色强调，导出 PNG/PDF 两种格式；

5. 后续计划：第一周完成数据清洗与基础图表（本报告内容）；第二周补充 Spearman 相关与卡方检验；第三周模型选型与初步建模；第四周计算敏感度/特异度/AUC 并整合报告初稿；第五周制作 PPT 与模拟汇报。